

用最直覺的方式從 SDE 走到 Probability Flow ODE（一維）

我們要把下列 隨機微分方程（SDE, Itô）

$$dx_t = f(x_t, t) dt + g(x_t, t) dW_t$$

改寫成一條 **沒有雜訊的 ODE**，

但要求：兩條路徑族在每個時間 t 上都產生**同樣的機率密度** $p(x, t)$ 。

最後答案會是

$$dx_t = \left[f(x_t, t) - \frac{1}{2} \partial_x g^2(x_t, t) - \frac{1}{2} g^2(x_t, t) \partial_x \log p(x_t, t) \right] dt$$

這條 deterministic ODE 就叫 **probability flow ODE**。

下面用「搬運機率的流量」來直觀推導。

0. 名詞介紹

- **密度** $p(x, t)$ ：在時間 t 時，樣本落在位置 x 的「機率濃度」。
- **機率流量** $J(x, t)$ ：單位時間內，從位置左往右「被搬運」的機率量。
把 p 想成水，把整條 x 軸想成水管， J 是水的**淨流速 × 濃度**。
- **關鍵守恆式（連續方程）**：
「某段區間裡的機率變化 = 進來多少 - 流出去多少」
轉成微分就是

$$\partial_t p(x, t) = -\partial_x J(x, t). \quad (\star)$$

1. SDE 的流量長什麼樣？

對 Itô 形式的 SDE

$$dx_t = f dt + g dW_t,$$

它的密度 p 滿足**Fokker–Planck 方程**：

$$\partial_t p = -\partial_x(f p) + \frac{1}{2} \partial_x^2(g^2 p). \quad (\text{FP})$$

把 (FP) 與 (★) 對比，就能讀出 **SDE 的機率流量**

$$J_{\text{SDE}}(x, t) = f(x, t) p(x, t) - \frac{1}{2} \partial_x(g^2(x, t) p(x, t)). \quad (1)$$

直覺：

- $f p$ ：漂移把「水」往 f 的方向推。
- $-\frac{1}{2} \partial_x(g^2 p)$ ：擴散會把高濃度往低濃度推（像在做**抹平**），所以出現空間導數。

初學者可以只先記住 (1)：**SDE 的流量 = 漂移造成的流量 - 擴散造成的「梯度流量」**。

2. ODE 的流量長什麼樣？

若我們用一條沒有噪聲的 ODE 來移動粒子：

$$\dot{x}_t = u(x_t, t),$$

那密度的變化只會來自「被速度場 u 搬運」，所以

$$\partial_t p = -\partial_x(u p),$$

因此 **ODE 的機率流量** 很單純：

$$J_{\text{ODE}}(x, t) = u(x, t) p(x, t). \quad (2)$$

3. 要兩邊密度一樣 \Rightarrow 讓兩邊流量一樣

我們的目標是：不論何時何地，兩套動力學搬運出的密度都一樣。

最直接的做法：把兩個流量直接設相等：

$$J_{\text{ODE}}(x, t) \equiv J_{\text{SDE}}(x, t).$$

把 (1) 與 (2) 代入，立刻得到

$$u(x, t) p(x, t) = f(x, t) p(x, t) - \frac{1}{2} \partial_x (g^2(x, t) p(x, t)).$$

只要 $p > 0$ （在機率有支撐的地方），除以 p ：

$$u(x, t) = f(x, t) - \frac{1}{2} \frac{\partial_x (g^2 p)}{p}. \quad (3)$$

把分子展開（就是乘法微分）：

$$\partial_x (g^2 p) = (\partial_x g^2) p + g^2 \partial_x p.$$

代回 (3) 並整理：

$$u(x, t) = f(x, t) - \frac{1}{2} \partial_x g^2(x, t) - \frac{1}{2} g^2(x, t) \frac{\partial_x p(x, t)}{p(x, t)}.$$

注意 $\partial_x \log p = (\partial_x p)/p$ ，所以

$$\boxed{u(x, t) = f(x, t) - \frac{1}{2} \partial_x g^2(x, t) - \frac{1}{2} g^2(x, t) \partial_x \log p(x, t).} \quad (4)$$

最後把 u 放回 ODE：

$$dx_t = \left[f - \frac{1}{2} \partial_x g^2 - \frac{1}{2} g^2 \partial_x \log p \right] dt,$$

這就是 **probability flow ODE**。完成。

4. 兩個「為什麼」的直覺

1. 為什麼會出現 $-\frac{1}{2} \partial_x g^2$?

擴散強度 g 在空間不均勻時，噪聲本身就會「偏向把粒子推向噪聲比較小的地方」——Itô 詮釋下要加這個修正，才能在 ODE 里重現同樣的淨流量。

2. 為什麼會出現 $-\frac{1}{2} g^2 \partial_x \log p$?

擴散會把高密度往低密度推，這種「往密度下降方向流動」在連續極限上就和 $\nabla \log p$ (score) 成正比。於是 ODE 只要沿著 $-g^2 \nabla \log p$ 方向再推一下，就能模擬擴散對密度的抹平效果。

5. 快速檢查 (sanity check)

- 常數擴散 $g \equiv \sigma$:

$\partial_x g^2 = 0$ ，所以

$$u = f - \frac{1}{2} \sigma^2 \partial_x \log p.$$

沒有空間變化的噪聲，只剩「沿著 score 往低密度方向推」的項。很合理。

- 零噪聲 $g \equiv 0$:

$u = f$ 。回到原本的 ODE，密度只被漂移搬運。

8. 結語

整件事就一句話：

把 SDE 的「機率流量」改用一个沒有噪聲的速度場 u 來搬運，而且讓兩邊的流量完全一樣。

解出 u 就得到 probability flow ODE。

AI 的未來與機器學習的基石

1. AI 的未來能力

題目能力：以「跨學科機理發現助理」自動提出可檢驗的新定律。

它能從生醫、材料、經濟等異質資料中，生成可重複、可反駁的假說（含變數關係、因果方向與可操作

的實驗設計)，並輸出**必要資料量**、**估計效應大小與風險**。

為何重要：

- 目前 AI 多做預測與總結；****真正創新的「可驗證機理」****仍仰賴少數人類專家。若能把「提出可檢驗假說」流程標準化，將大幅縮短從資料到知識的周期。
- 在醫療與能源上，這代表**更快的藥物靶點發現與高效材料設計**；在公共政策上，能提出**低成本準實驗**來估計介入效果。

典型場景：「自動產出 CRISPR 實驗方案以測試某代謝通路的因果方向」「為鋰電新電解質生成反應機制與 3 項關鍵驗證實驗」。

2. 涉及的機器學習類型與理由

- **監督式學習 (SL)：**
 - 用途：表徵學習與基礎預測模型（結構式/序列式預測、實驗成敗分類）。
 - 標註來源與目標訊號：歷史論文資料庫、公開數據集、LIMS 實驗結果；目標是數值效能或成敗標籤。
- **非監督式學習 (UL) 與表徵學習：**
 - 用途：在跨模態資料（文本、圖譜、結構、時間序列）中學習**潛在變量與結構稀疏性**，為因果與規則歸納做前處理。
- **因果學習 / 結構學習 (Causal + Graphical Models)：**
 - 用途：從觀測資料與干預碎片中推斷圖結構，估計可辨識的因果效應。
- **強化學習 (RL) / 主動實驗設計 (Active Learning, Bayesian Optimization)：**
 - 用途：在「實驗昂貴」情境下，**規劃下一步最有價值的實驗**；回饋是實驗獲得的效用（信息增益、價值函數）。
- **人機互動學習 (HF/HITL)：**
 - 用途：納入專家先驗與可解釋約束；由人提供**結構先驗/不變性規則**作為正則化。
- **是否要與環境互動？**
 - 需要。系統必須在「**提出—實驗—更新**」的閉環中運作（線上同化新證據）。

3. 第一研究步驟的「模型化」

最小可行問題 (Model Problem)：

以「小分子—表型效應」為例，建立一個能**產生並評分可檢驗假說**的閉環：

1. **資料與表徵**：蒐集分子圖（SMILES/3D）、多組學與已有干預結果；以圖神經網路與變分自編碼器學到共享潛在空間。
2. **結構學習**：以稀疏可解釋的因果圖（NOTEARS/FCI + 結構先驗）得到候選因果邊。
3. **假說產生器**：把候選邊轉成**操作性假說**（變數、預期方向、效應大小先驗、控制變項）。
4. **實驗規劃（RL/BO）**：以**信息增益最大化**為回饋選擇下一個實驗；安全約束來自專家規則與成本上限。
5. **評估指標**：
 - 離線：在合成/模擬資料的「已知真相」上測**結構恢復率（SHD/F1）**、效應估計誤差（PEHE/ATE 誤差）。
 - 在線：每單位成本的**發現率**、重複驗證通過率、對外部資料集的轉移性。
6. **成功判準**：在固定實驗預算下，相比基線（隨機或貪婪）達成**更高的真實陽性數與更低的假陽性**，且假說可被人類審核理解。
7. **需要的工具**：大語言模型做文獻抽取與實驗步驟標準化；圖學習/因果結構學習套件；貝葉斯最佳化與主動學習框架；一個小型濕實驗或高可信模擬器作為在線回饋來源。

核心精神：把「知識生產」拆成**表徵** → **結構** → **假說** → **實驗** → **校正**五步，並以**可檢驗性與成本效率**作為第一性原則來設計學習與評估。